

Paulo Eduardo dos Santos

Senior Data Engineer | Big Data Specialist

Americana - São Paulo, Brazil | +55 11 91526-7337 |

paulo_eduardosp@yahoo.com.br

<https://www.linkedin.com/in/paulo--eduardo/>

Resumo das Qualificações

- Experiência com ferramentas de integração e orquestração de dados: Apache Airflow, Apache NiFi, Talend Data Integrator, DataStage, SQL Server Data Tools (Integration Services - SSIS), Informatica BDM e PowerCenter.
- Experiência em projetos de Governança, Arquitetura e Qualidade de Dados, Data Lake, Data Warehouse e implementação de Metodologia Ágil para Analytics com Scrum e SAFe.
- Experiência com ambientes em Cloud: AWS (S3, EMR, Redshift, Athena, Glue, Lambda, Kinesis), Azure (Data Lake, Databricks, Data Factory, Synapse, Unit Catalog, Fabric), Google Cloud Platform (BigQuery, Dataproc) e dbt.
- Experiência em metodologia de levantamento de requisitos em projetos de Analytics, criação de pipelines ETL/ELT e Modelagem Dimensional.
- Experiência com ferramentas de visualização de dados: Power BI, QlikSense, Tableau, SpotFire, MicroStrategy e Oracle Business Intelligence - OBIEE.
- Experiência em definir e implementar arquiteturas de: Big Data, Data Lake, Data Lakehouse e Data Warehouse (Star Schema e Snow Flake) e Snowflake.
- Experiência com Databases: SQL Server, Azure SQL Database, Azure Synapse, PostgreSQL, MySQL, Oracle, Teradata, MongoDB, Cassandra, HBase, DynamoDB e Redshift.
- Conhecimentos em ecossistemas de Big Data: Hadoop, Spark, PySpark, Hive, HBase, Sqoop, Flume, HDFS, Yarn, MapReduce, Kafka, NiFi, Impala e Databricks.

Technical Skills

Soluções e Arquitetura: Arquitetura Big Data (Ecossistemas Hadoop/Spark), Arquitetura Data Lake & Lakehouse (Bronze/Silver/Gold), Design de Data Warehouse (Star Schema, Snowflake Schema), Governança de Dados & Qualidade de Dados, Estratégias de Migração para Nuvem (On-prem para Cloud), Design de Pipelines ETL/ELT, Metodologias Ágeis para Dados (Scrum, SAFe)

Cloud: AWS (S3, EMR, Redshift, Athena, Glue, Lambda, Kinesis), Azure (Data Lake, Databricks, Data Factory, Synapse, Fabric), GCP (BigQuery, Dataproc)

Processamento/Orquestração: Apache Airflow, Apache NiFi, Spark, PySpark, Talend, DataStage, SSIS, Informatica PowerCenter, DBT, Kafka

Bancos de Dados: SQL Server, Oracle, Teradata, PostgreSQL, MySQL, MongoDB, Cassandra, HBase, DynamoDB, Snowflake

Visualização: Power BI, QlikSense, Tableau, Spotfire, MicroStrategy, OBIEE

Experiência Profissional

BRQ - Engenheiro de Dados

Project: RD - Data Lake de Saúde (Visão 360 do Cliente)

- Construção de Data Lake de Saúde com arquitetura medallion (bronze / silver / gold) sobre Apache Iceberg em S3, suportando casos de uso de prontuário eletrônico, agendamento, vacinas, medicamentos, receituário, teleinterconsulta e prescrição (Amplimed, HAOC, Vitat).
- Desenvolvimento de pipelines PySpark / SparkSQL para ingestão, transformação e consolidação de dados clínicos em larga escala, com suporte a Apache Iceberg e Apache Hudi.
- Orquestração de DAGs em Apache Airflow integradas a Spark on Kubernetes (K8s), com geração automatizada de manifests YAML por meio de builders Python (build_yamls).
- Modelagem da tabela analítica Visão 360 do Cliente integrando múltiplas fontes (CRM, agendamentos, eventos, interesses) via Trino, Athena e Redshift.
- Implementação de framework próprio de Data Quality (validações cross-origin, light checks, DLS validations) e manutenção de catálogo de dados versionado em YAML.
- Governança e segurança de dados sensíveis de saúde (PII / LGPD) com HashiCorp Vault, AWS KMS e criptografia Fernet, incluindo pipelines de decrypt em landing.
- Integração de ingestão via APIs (Amplimed, HAOC, Precifica, bloqueio de agenda) com clientes assíncronos em S3 e tratamento de schemas evolutivos (JSON / Parquet / Iceberg).
- Implementação de observabilidade end-to-end com handlers customizados de logs, métricas Spark, exceptions e comentários de tabelas Iceberg, integrados a AWS SNS e Step Functions.
- Manutenção de containers Docker (dev / qa / prod) para os jobs PySpark e Python K8s do data lake.

Project: Itaú - Modernização e Analytics

- Desenvolvimento de pipelines ETL utilizando EMR Serverless e Glue Studio.
- Otimização de consultas SQL para melhoria de performance.
- Implementação de processos de data quality.
- Análise de Testes A/B.
- Desenvolvimento de análises de melhoria de métricas e hipóteses dos testes.

Stefanini - Especialista em Big Data / Engenheiro de Dados

06/2023 - 06/2025 | Brazil

Project: Banco do Brasil - Sustentação de Ambiente Big Data

- Sustentação e otimização de cluster Cloudera/Hortonworks em ambiente de produção.
- Desenvolvimento de scripts Python e Shell para automação de processos operacionais.
- Implementação de notebooks Jupyter para análise exploratória de dados.
- Configuração e manutenção de jobs Ansible para gestão de infraestrutura.
- Desenvolvimento de consultas otimizadas em Hive e manutenção de estruturas HDFS.
- Desenvolvimento de modelos de dados com dbt em Snowflake para relatórios financeiros, incluindo testes de qualidade e versionamento de transformações.

Project: AmericaNet - APIs e Manipulação de Dados

- Desenvolvimento de API RESTful em Python Flask para exposição de dados processados.
- Implementação de transformações de dados complexas utilizando SparkSQL no Databricks.
- Criação de notebooks para processamento e análise de dados.
- Automação de processos utilizando Azure Automation.

- Desenvolvimento de pipelines de dados com tratamento de erros e logging.
- Construção de pipelines ELT com dbt em Snowflake, modelando dados para consumo por APIs com validações de integridade, unit catalog.

Project: Cielo - Dashboard Analytics

- Análise e documentação de procedures Oracle legadas.
- Desenvolvimento de scripts PySpark para processamento de grandes volumes de dados.
- Criação de tabelas externas no Athena sobre dados em S3.
- Otimização de consultas SQL para melhoria de performance.
- Implementação de particionamento de dados em S3.
- Migração de dados analíticos para Snowflake, com dbt para modelagem dimensional e suporte a dashboards em Power BI.

Project: Itaú - Refatoração de Processos ETL

- Refatoração de tabelas SQL legadas para formato Parquet.
- Conversão de stored procedures para jobs PySpark.
- Desenvolvimento de catálogo de dados utilizando AWS Glue.
- Implementação de processos de data quality.
- Documentação técnica detalhada de todos os processos migrados.

Project: DirectLog Sistema de Geolocalização

- Criação de esteira para captura de latitude e longitude via API Google Maps.
- Desenvolvimento de DAGs Airflow para processamento batch de endereços.
- Implementação de interface web com acesso autenticado SFTP.
- Configuração de servidor EC2 para hospedar a aplicação.
- Desenvolvimento de sistema de cache para otimizar chamadas à API.

Project: Data Lake AWS - Brasildev

- Construção de Data Lake com arquitetura em camadas (bronze, silver, gold).
- Desenvolvimento de catálogo de dados e implementação de governança.
- Criação de motor de ingestão de dados em Python.
- Integração com Salesforce para captura de dados.
- Configuração de políticas de segurança e acesso com Lake Formation.
- Automação de infraestrutura utilizando Terraform.

Natura & Co - Engenheiro de Dados

02/2022 - 06/2023 | Brazil

Project: Pipeline de E-commerce

- Modelagem dimensional de dados para suportar análises de e-commerce.
- Desenvolvimento de pipelines ETL utilizando EMR Serverless.
- Implementação de DAGs Airflow para orquestração de processos.
- Criação de estruturas Delta Lake para versionamento de dados.
- Desenvolvimento de processos incrementais de carga.
- Integração com ferramentas de BI através do Redshift.

- Construção de modelos de dados com dbt em Snowflake para análises de comportamento de clientes, com testes de qualidade de dados.

Project: Cielo - Migração para Cloud e Modernização

- Análise de estruturas de dados Oracle e mapeamento para BigQuery.
- Desenvolvimento de scripts para monitoramento de spark submit.
- Migração de dados legados para Azure Blob Storage.
- Implementação de pipelines no Azure Data Factory, criação e atualização do catálogo de dados Unit catalog.
- Conversão de lógicas SQL complexas para processamento distribuído.
- Desenvolvimento de códigos PySpark e SparkSQL Databricks.

Project: JBS - Modernização de Pipeline de Dados

- Liderança técnica de equipe de engenheiros e desenvolvedores.
- Implementação de cluster NiFi de alta disponibilidade.
- Integração do NiFi com Active Directory para autenticação centralizada.
- Configuração de Application Load Balancer para distribuição de carga.
- Desenvolvimento de fluxos NiFi para ingestão de dados do SAP.
- Implementação de processos de movimentação de dados entre S3 e Redshift.

Enel - Engenheiro de Dados

05/2021 - 02/2022 | Brazil

Project: Migração de Data Warehouse

- Desenvolvimento de pipeline de migração utilizando Talend Open Studio.
- Movimentação de dados do Impala para Redshift.
- Criação de dashboards no QlikSense conectados ao Redshift.
- Documentação de processos ETL existentes.
- Otimização de queries para melhoria de performance.
- Treinamento da equipe de negócios nas novas ferramentas.

Banco do Nordeste - Arquiteto de Soluções Big Data

01/2021 - 05/2021 | Brazil

Project: Implementação de Data Lake Corporativo

- Design de arquitetura de Data Lake com zonas raw, stage e analytics.
- Implementação de cluster Hadoop não gerenciado.
- Configuração do Dremio para camada de analytics.
- Planejamento de estrutura NoSQL com Cassandra para sistema de créditos.
- Integração com sistemas legados através de DataStage.
- Desenvolvimento de documentação de arquitetura.

Project: Bradesco - Framework de Ingestão de Dados

- Atualização de scripts do framework de ingestão para tabelas Hive e HBase.
- Desenvolvimento de shell scripts para automação de processos.
- Integração com scheduler IBM IWS para agendamento de jobs.

- Conexão com bases Teradata para extração de dados.
- Otimização de processos de carga e transformação.

Hospital Sírio Libanês - Arquiteto/Engenheiro Big Data

03/2019 - 12/2020 | Brazil

Project: Plataforma de Analytics Hospitalar

- Análise e ingestão de dados hospitalares de múltiplas fontes.
- Instalação e configuração do Airflow para orquestração.
- Desenvolvimento de DAGs para automação de processos ETL.
- Implementação de containers Docker integrados com Airflow.
- Configuração de Kubernetes para escalabilidade.
- Integração AWS Cognito com AD Azure para SSO.
- Configuração de pipeline CloudWatch para Elastic Search via Lambda.

Project: Projeto Raízen - Framework de Ingestão de Dados

- Levantamento de arquitetura de pipeline de dados.
- Análise de Azure Data Lake, Databricks e Power BI.
- Documentação de processos de integração SAP via SSIS Theobald.

Project: Dell EMC - Consultoria e Treinamento - Cliente Fleury

- Análise de dados e sustentação de ambiente Hortonworks.
- Configuração de segurança com Kerberos/Ranger e integração com AD.
- Desenvolvimento de scripts de monitoração para jobs Oozie.
- Treinamento operacional para equipe do cliente.
- Implementação de dashboards de monitoramento com Grafana.

Claro Brasil - Líder Técnico Big Data

09/2017 - 03/2019 | Brazil

Project: Implementação de Clusters Cloudera

- Instalação e configuração de 3 clusters Cloudera para projetos distintos (Data Lake, M2M, BI).
- Implementação de Kerberos com AD como KDC para segurança.
- Integração Hive/Impala com ferramentas de BI (SAS, QlikView, Alteryx).
- Desenvolvimento de framework de ingestão de dados.
- Configuração de Cross-Realm entre clusters em diferentes domínios.
- Criação de scripts de monitoração e sustentação.
- Integração com Informatica BDM para processos ETL.

Project: Nextel - Sustentação e ETL

- Desenvolvimento de processos ETL para ingestão de dados.
- Análise de dados utilizando Beeline e Impala.
- Extração de dados via Sqoop de bases relacionais.
- Levantamento de requisitos funcionais.
- Sustentação do ambiente de produção.

Vivo - Analista Big Data

06/2017 - 09/2017 | Brazil

Project: Migração e Sustentação Hadoop

- Processos ETL para ingestão de dados.
- Análise de dados com Hive e Python.
- Migração de Hadoop 2.2 para 2.6.
- Persistência de dados em HBase.
- Gestão de cluster com Zookeeper.

Formação Acadêmica

Inteligência Artificial (Em andamento) - FMU (Present)

Bacharelado em Sistemas de Informação - UNIP (2006)